

Relatório de limpeza de dados

Integrantes: Wesley Bernardes (020321) e Lucas Faria (020321)

Introdução

Esse relatório apresenta o processo de limpeza de dados realizado no dataset "Netflix Movies and TV Shows", disponível na plataforma Kaggle.

O objetivo foi organizar e padronizar uma base de dados para permitir análises, identificando padrões e gerando insights sobre os filmes e séries da Netflix.

Como foi feita a limpeza

A base de dados original apresentava os seguintes problemas:

- Presença de valores nulos em colunas como 'director', 'cast' e 'country'.
- Registros duplicados.
- Coluna 'date_added' armazenada como texto, dificultando análises temporais.
- Inconsistências em campos de texto, como espaços extras em 'country'.

As etapas aplicadas para a limpeza foram:

- Presença de valores nulos em colunas como 'director', 'cast' e 'country'.
- Registros duplicados.

- Coluna 'date_added' armazenada como texto, dificultando análises temporais.
- Padronização dos valores da coluna `country`.

Resultados

Os principais resultados encontrados após a limpeza do dataset foram:

- O catálogo é predominantemente composto por filmes em comparação às séries.
- Estados Unidos, Índia e Reino Unido são os países que mais contribuem com títulos na plataforma.

Conclusão

Pode-se concluir que a Netflix possui um catálogo majoritariamente de filmes, com forte concentração de produções nos Estados Unidos e Índia.