

Relatório de limpeza de dados de empregos

Integrantes: Wesley Bernardes (020321)

Introdução

Esse relatório apresenta o processo de limpeza de dados realizado no dataset “[Novice to Grandmaster](#)”, disponível na plataforma Kaggle.

O objetivo foi organizar e padronizar uma base de dados para permitir análises, identificando padrões e gerando insights sobre país de origem, cargo e idade das pessoas que responderam a pesquisa.

Como foi feita a limpeza

A base de dados original apresentava os seguintes problemas:

- Registros duplicados.
- Inconsistências em campos de texto (ex.: espaços extras e capitalização) na coluna `CurrentJobTitleSelect` (cargo) e `Country` (país).
- Países múltiplos na mesma célula (ex.: “Brasil, Argentina”), o que dificulta contagens.
- Idade em formato textual e presença de outliers (idades fora do intervalo razoável de análise).

As etapas aplicadas para a limpeza foram:


- Remoção de duplicados com `drop_duplicates()`.
- Padronização de cargos: `strip()` + `title()` em `CurrentJobTitleSelect` e exclusão da categoria genérica “Other”.

- Padronização de países: `fillna("Indefinido")`, conversão para `str`, uso apenas do primeiro país quando havia mais de um (split por vírgula), `strip()` e exclusão de "Other".
- Padronização de idades: extração numérica via regex para `Age_num`, conversão para número e filtro para manter idades entre 16 e 50 anos (inclusive), preservando nulos.

Resultados


Algumas das análises feitas foram:

- Distribuição por país:



País com mais respondentes: **United States (3.209)**.

- Distribuição por cargo:



Cargo mais comum: **Data Scientist (2.210)**.

Conclusão

Após a limpeza, a amostra ficou mais consistente para análise ao retirar duplicidades, padronizar texto em país e cargo, tratar idades e resolver linhas com múltiplos países.

Observamos forte concentração de respondentes nos Estados Unidos e na Índia e uma predominância do cargo Data Scientist na amostra.