

Relatório dos dados da tabela de diamantes

Lucas Faria (019790) e Wesley Bernardes (020321)

Com relação à média do preço (price), foi obtido um valor de 3.930,993, enquanto a mediana foi de 2.401,000. Como a média é maior que a mediana, espera-se que a curva não seja simétrica e possua assimetria positiva (cauda à direita). Essa assimetria é confirmada pelo valor de skewness = 1,618, indicando que a curva realmente apresenta a cauda à direita.

Além disso, também é possível definir se os dados são esparsos ou não. Como a média é 3.930,993 e o desvio-padrão é 3.987,280, conclui-se que os dados não estão concentrados próximos à média, mas sim espalhados. Essa conclusão é reforçada pelo valor de curtose (excesso) = 2,178, indicando caudas mais pesadas e maior dispersão.

Isso pode indicar a presença de outliers ou apenas a heterogeneidade natural dos dados. Para verificar essa informação, analisamos os valores mínimos e máximos do preço: mín = 326,000 e máx = 18.823,000. Como a média é próxima de 3.931, é razoável suspeitar que os maiores valores pertençam à cauda e possam conter outliers.

Para analisar formalmente os outliers, utilizamos o critério $\text{média} \pm 3 \cdot \text{desvio-padrão}$:

$$\text{limites} = [3.930,993 \pm 3 \times 3.987,280] \Rightarrow [-8.030,85; 15.892,83]$$

Logo, pode-se afirmar que valores acima de 15.892,83 são outliers de preço. Contabilizamos 1.206 observações ($\approx 2,24\%$) acima desse limite; o limite inferior negativo é apenas teórico (preços negativos não ocorrem).

De modo análogo, para carat (quilates), obteve-se média = 0,798 e mediana = 0,700. Espera-se assimetria à direita, confirmada por skewness = 1,116, e curtose (excesso) = 1,255. Com o mesmo critério $\pm 3 \cdot \text{DP}$, os limites são $[-0,624; 2,219]$, e observamos 436 casos ($\approx 0,81\%$) acima do limite superior, considerados outliers de quilates.

Os histogramas a seguir confirmam visualmente essas conclusões: no histograma do preço nota-se a assimetria e a presença de outliers à direita; no histograma de carat há padrão similar (concentração em valores baixos e cauda direita).




Figura 1 – Histograma do preço (com limites $\pm 3 \cdot DP$).




Figura 2 – Histograma de quilates (com limites $\pm 3 \cdot DP$).

Além disso, os boxplots evidenciam pontos além dos “bigodes”, caracterizando outliers segundo o critério do IQR:




Figura 3 – Boxplot do preço (outliers).




Figura 4 – Boxplot de quilates (outliers).

Esses outliers podem ser removidos e as análises podem ser refeitas. Após remover outliers de price, os novos valores são: média = 3.625,739, mediana = 2.330,500, desvio-padrão = 3.475,608, skew = 1,454 e curtose (excesso) = 1,551. Observa-se que a curva continua assimétrica, porém com cauda direita menor e menor dispersão.




Figura 5 – Preço após remoção de outliers.




Figura 6 – Quilates na amostra filtrada por preço.

Análise conjunta das variáveis

Primeiramente, é apresentado um mapa de calor (heatmap) com as correlações entre as variáveis numéricas (price, carat, x, y, z, depth, table, e as versões numéricas de cut, color, clarity). Em Pearson, as maiores correlações do preço aparecem com as medidas de tamanho: $\text{corr}(\text{price}, \text{carat}) = **0,922**$, $x = **0,887**$, $y = **0,868**$, $z = **0,868**$. As associações com table (0,127) e depth (-0,011) são fracas. Em Spearman, os resultados são muito próximos: $x = **0,964**$, $\text{carat} = **0,963**$, $y = **0,963**$, $z = **0,959**$.




Figura 7 – Mapa de calor (Pearson)




Figura 8 – Mapa de calor (Spearman).

Pela análise dos mapas de calor, nota-se que a maior relação com o preço é com carat. Sendo assim, aprofunda-se a análise dessas duas variáveis por meio de um Scatterplot com linha de tendência. A figura abaixo mostra uma diagonal acentuada, confirmando a correlação forte e positiva: conforme quilates aumentam, o preço também aumenta.

Além disso, a regressão linear simples $\text{price} \sim \text{carat}$ apresenta $R^2 = 0,849$, inclinação $\approx 7.755,77$ (US\$ por 1 quilate) e intercepto $\approx -2.255,77$, reforçando a magnitude dessa associação.




Figura 9 – Relação preço × quilates (linha de tendência).

Outras análises bivariadas (qualidade x preço)

Também foram avaliados efeitos de qualidade na precificação via gráficos por categoria:

- price × cut (Fair → Ideal): as medianas brutas por categoria são 3.282 (Fair), 3.050 (Good), 2.647 (Very Good), 3.182 (Premium) e 1.810 (Ideal). A ordem não é monotônica porque tamanho varia dentro de cada categoria; ainda assim, quando se controla por quilates e demais variáveis (ver regressão múltipla), melhor corte aumenta o preço.




Figura 10 – Preço por corte (Fair→Ideal)

- price × color (J → D): as medianas brutas decrescem (J 4.234, I 3.730, H 3.454, G 2.240, F 2.344, E 1.739, D 1.836), reflexo de diferenças de tamanho entre cores. Controlando pelos demais fatores, o efeito de melhor cor é positivo.




Figura 11 – Preço por cor (J→D).

- price × clarity (I1 → IF): padrão semelhante, com medianas brutas maiores nas classes piores (I1 3.346, SI2 4.072, ..., IF 1.080), novamente por confusão com carat; no ajuste multivariado, maior pureza aumenta o preço.




Figura 12 – Preço por pureza (I1→IF).

Por fim, o gráfico depth × table mostra dispersão sem padrão linear forte, sinalizando que essas medidas afetam mais a proporção/atratividade do diamante do que o preço diretamente.




Figura 13 – Profundidade $\times$ mesa.

As possíveis conclusões da análise são as de que, conforme os quilates (carat) aumentam, o preço do diamante também aumenta de forma clara, sendo o tamanho o principal determinante do valor. Além disso, características de qualidade (corte, cor e pureza) agregam prêmio ao preço quando o efeito do tamanho é controlado, ainda que com impacto menor do que o de carat. Observou-se a presença de outliers, sobretudo em price; porém, as conclusões com e sem outliers permaneceram praticamente as mesmas, indicando que eles podem ser considerados no estudo sem prejuízo aos resultados. Isso sugere que os valores extremos são raros, mas plausíveis, refletindo casos reais em vez de erros de registro.